

JurisMMA

多模态多智能体赋能的法律判决预测

Abstract

法律判决预测 (LJP Legal Judgement Prediction): 基于事实描述预测法律案件的结果。

LJP框架,

- JurisMMA, 有效地分解审判任务、规范流程并将其组织成不同的阶段。
- JurisMM1, 包含10万条近期中国司法记录的大型数据集, 其中包括文本和多模态视频文本数据。

Introduction


法律语言具有高度专业化、复杂性以及对精确术语依赖极高等特点, 这给LJP带来了显著挑战。

- 简化真实法庭的模拟过程
- 使用RAG
- 优化提示工程

尽管NN分类器在简单预测任务重表现良好, 但它们往往难以建模真实庭审中复杂的程序性流程与多方交互过程。

- 真实场景复现, 多数框架无法:
 - 同时预测多个罪名/法律条款
 - 利用多模态证据 (如庭审视频) 导致预测准确性受限
- 多变量交互, 现有方法的问题:
 - 角色模拟过于单一
 - 忽略不同角色之间的共享功能与流程设计
 - 结论片面&审判逻辑不合理

JurisMMA 一个多智能体法律判决预测框架, 利用大语言模型的推理能力来模拟真实法庭过程。



包含两个核心模块:

1. 多智能体法庭模块, 包含6个角色: 初级法官, 高级法官, 首席法官, 助手, 被告, 辩护律师。
流程: 案件记录 输入——> 初级法官提取案件信息 ——> 高级法官进行核查 ——> 生成案件总结——> 被告与律师参与 ——> 最终由首席法官裁决 ——> 如不满意, 可上诉
2. 例, 生成指控。(RAG+法律知识增强推理)

数据集 (JurisMM)，一个新数据集，超过10万条真实案件，来源于官方，包含文本数据与多模态数据（83个视频-文本样本），解决了现有benchmark过时的问题。

Method

六阶段审判流程

阶段	角色
信息提取	Junior Judge
校验	Senior Judge
推理辅助	Assistant
审理决策	Chief Judge
辩护	Legal Counsel
陈述/上诉	Defendant

这 6 个阶段本质上构成了一个 “多智能体 + 检索增强 + 结构化决策 + 可上诉闭环” 的法律推理系统。

Experiments and results

为解决现有法律文本数据集（如 CAIL2018）存在的“内容过时”问题，我们从中国裁判文书网收集了 2014 年至 2024 年初共计 150,000 份公开刑事判决书，覆盖所有类型的刑事案件。为确保数据符合《中华人民共和国刑法（2023 年修正案）》的规定，我们剔除了涉及 2014–2025 年期间修订条款的案件，并对类别分布进行了平衡处理。最终，构建了 JurisMM-Text 子集，共包含 101,544 个案件，其中：

- 94,494 条用于训练
- 7,050 条用于测试

为补充多模态法律数据，我们设计了一套半自动化流程来构建 JurisMM-Video 子集：

- 首先，对视频进行分段处理，并利用视觉-语言模型筛选与犯罪现场、证据或嫌疑人行为相关的片段；
- 随后，由法律专家对筛选结果进行人工审核，选取关键帧并设计问题；

最终，该流程生成了 83 个高质量的多模态样本，这些样本能够捕捉关键视觉信息，例如

- 证据
- 场景结构
- 嫌疑人行为

从而支持具备上下文理解能力的法律判决预测。

除了数据集之外，我们还构建了一个面向法律领域的知识库，该知识库基于 2023 年刑法修正案，包含三个核心组成部分：

- 法律条文 (Legal Content)**：包含来自国家法律法规数据库（2023）的 438 条现行刑法条款，并辅以最高人民法院的司法解释；
- 罪名库 (Charges)**：包含 483 类主要罪名的结构化列表，用于预测与检索；
- 判例库 (Precedents)**：包含从 JurisMM-Text 中筛选出的 46,365 个代表性案例，用于辅助法律推理。

Baselines

对于传统神经网络方法，我们选取了具有代表性且具有竞争力的基线模型，包括：

- TextCNN

- TOPJUDGE [4]
- MPBFN [5]

用于对我们的框架进行对比评估。尽管这些模型相对较早提出，但由于近年来在法律领域专用神经架构方面缺乏显著突破，它们在 JurisMM 数据集上仍然保持一定竞争力。

对于基于大语言模型（LLM）的基线方法，我们评估了以下开源模型：

- GLM-4V-9B [19]
- mPLUG-Owl-7B [20]
- Qwen2.5-VL-3B / 7B-Instruct [21]
- Qwen2.5-7B-Instruct [22]

以及闭源模型：

- GPT-4o-20250326 [23]

Experiments setup

对于神经网络模型，我们在 JurisMM-Text 的训练集上进行训练，并在测试集上进行评估。训练过程中采用：

- Adam 优化器
- 学习率： 10^{-3}
- Dropout 比例：0.5
- Batch size：512
- 训练轮数：16 个 epoch

对于大语言模型（LLMs）：

- **闭源模型**：将 temperature 固定为 0，以保证输出的确定性；
- **开源模型**：每个模型运行 3 次，并报告平均结果；

JurisMMA 框架主要使用 GPT-4o，同时还使用 Qwen2.5-VL-7B 进行了额外实验，以测试模型的泛化能力。每个输入平均消耗约 20,000 个 token（具体取决于案件复杂度）。

在性能评估方面，我们采用四种常用的多分类指标：

- 准确率（Accuracy, Acc.）
- 宏精度（Macro-Precision, MP）
- 宏召回率（Macro-Recall, MR）
- 宏 F1 值（Macro-F1, F1）

Overall Performance

三个任务难度排序：Law Articles法条预测（最容易） > Charges 罪名预测 > Terms of Penalty 刑期预测（最难）

单纯的LLM不能做法律推理，结构才是关键。

- GPT-4o = 推理能力
- JurisMMA = 推理 + 结构 + 约束 + 交互（多 agent 分工，RAG，程序化流程）

Table1

文本数据集上的表现，不同模型在纯文本法律案件数据集上的整体表现以及针对 JurisMMA 的消融实验结果。

Model	Law Articles				Charges				Terms of Penalty				
	Acc.	MP	MR	MF	Acc.	MP	MR	MF	Acc.	MP	MR	MF	N-Id
TextCNN	0.703	0.389	0.343	0.334	0.696	0.492	0.457	0.441	0.325	0.321	0.282	0.285	—
TOPJUDGE	0.768	0.455	0.411	0.400	0.751	0.516	0.519	0.491	0.373	0.358	0.364	0.342	—
MPBFN	0.755	0.467	0.391	0.391	0.707	0.427	0.416	0.387	0.324	0.343	0.267	0.263	—
GLM-4V-9B	0.095	0.019	0.027	0.015	0.476	0.169	0.120	0.119	0.199	0.320	0.197	0.163	0.668
mPLUG-7B	0.094	0.027	0.035	0.019	0.319	0.093	0.060	0.058	0.100	0.250	0.168	0.067	0.507
Qwen2.5-VL-3B-Instruct	0.220	0.089	0.072	0.057	0.258	0.109	0.068	0.068	0.193	0.169	0.122	0.100	0.787
Qwen2.5-VL-7B-Instruct	0.271	0.133	0.121	0.092	0.134	0.061	0.021	0.026	0.188	0.135	0.119	0.096	0.799
Qwen2.5-7B-Instruct	0.523	0.133	0.170	0.123	0.590	0.161	0.144	0.134	0.237	0.227	0.145	0.124	0.826
GPT-4o-20250326	0.380	0.264	0.207	0.186	0.436	0.253	0.186	0.182	0.372	0.432	0.357	0.319	0.842
Qwen2.5-VL-7B(SFT)	0.365	0.207	0.241	0.200	0.515	0.295	0.277	0.252	0.252	0.123	0.096	0.040	0.818
JurisMMA (w GPT-4o)	0.872	0.604	0.645	0.602	0.882	0.600	0.642	0.603	0.409	0.520	0.393	0.361	0.848
w/o KB	0.653	0.323	0.323	0.281	0.801	0.203	0.190	0.187	0.378	0.454	0.371	0.335	0.848
w/o MA	0.767	0.592	0.607	0.569	0.773	0.581	0.599	0.566	0.303	0.475	0.304	0.272	0.803
JurisMMA (w Qwen2.5-VL-7B)	0.624	0.268	0.313	0.264	0.618	0.384	0.424	0.370	0.189	0.175	0.123	0.103	0.784
w/o KB	0.389	0.159	0.143	0.132	0.414	0.191	0.116	0.129	0.216	0.258	0.148	0.132	0.782
w/o MA	0.579	0.254	0.293	0.253	0.604	0.341	0.382	0.336	0.207	0.255	0.149	0.125	0.789

Table 1: Overall performance and ablation results on *JurisMM-Text*.

模型表现分层：表格底部的 **JurisMMA(w GPT-4o)** 在几乎所有任务的准确率和 F1 上都取得了最高分，远超其他基线模型。

通用大模型不经过微调，在专业法律任务上甚至不如传统的神经网络。

即便对 `Qwen2.5-VL-7B` 进行了针对性的微调，其表现不如采用了多智能体协作架构的 JurisMMA。

一旦去掉知识库或多智能体协作，单框架 JurisMMA 各项指标都会出现断崖下跌。特别是去掉知识库。

Table2

多模态/视频是剧集上的表现（JurisMM-Video），模型在包含视觉信息（83个多模态案件）的数据集上的表现。

视觉信息的增益，引入案件的视觉信息后，模型在法条预测、罪名预测上的准确率和F1都获得了稳定的提升。